PROYECTO FINAL · DEEP LEARNING Y SISTEMAS INTELIGENTES

Text-to-SQL en producción

Un modelo QLoRA que convierte preguntas en español en consultas MySQL seguras y revisables.

Wilson Alejandro Calderón Argueta · 22018
Pablo Daniel Barillas Moreno · 22193

PROBLEMA, USUARIO Y DECISIÓN

El analista necesita SQL confiable sin escribirlo

Usuario

Una persona que conoce el negocio y el esquema, pero depende de un especialista para consultar la base.

Decisión

Qué consulta de lectura usar para responder una pregunta operativa.

Contrato del servicio

Entrada
DDL MySQL + pregunta en español

Salida
Una consulta SELECT o WITH ... SELECT

Control
Sin escritura y sin conexión a datos reales

El usuario revisa el SQL antes de ejecutarlo. El servicio reduce la barrera técnica, pero no reemplaza permisos ni juicio humano.

MODELO DE ORIGEN Y VALIDACIÓN

QLoRA superó los criterios definidos antes de entrenar

VARIANTE	EX PONDERADA	EJECUTABLE	P95
Qwen base	3.8%	62.5%	6.66 s
QLoRA r=16	97.4%	97.5%	15.72 s
QLoRA r=32	**97.4%**	**97.5%**	**13.20 s**

≥70%

meta de EX

+15

puntos mínimos sobre baseline

39/40

respuestas correctas

> r=32 no mejoró la exactitud frente a r=16. Ganó por menor latencia p95 después del empate.

ARQUITECTURA DE PRODUCCIÓN

La aplicación limita la entrada, la salida y el uso de GPU

Cloudflare → **Next.js** → **FastAPI** → **Qwen + QLoRA** → **Guardia SQL**

URL temporal verificada. | Formulario y proxy permitido. | Contrato y control de cola. | GPU local y revisiones fijadas. | Una consulta de lectura.

1
generación simultánea

0
credenciales solicitadas

2
revisiones de modelo fijadas

PLANIFICACIÓN

Cuatro puertas antes del 9 de noviembre

1

2–3 nov

Migración, procedencia y pruebas de contrato.

2

4 nov

Interfaz, seguridad y telemetría privada.

3

5–6 nov

Despliegue y validación desde otra sesión.

4

7–8 nov

Evidencias, documentación y ensayo.

Wilson

Auditoría independiente final en Markdown y presentación oral.

Pablo

Runtime, interfaz, despliegue, evidencia y documentación.

El repositorio del Proyecto 3 registra dos integrantes. No se atribuyó trabajo a una tercera persona ficticia.

EXPERIENCIA DE USO

Una persona externa puede generar y revisar SQL

1

Pegar esquema

La interfaz incluye un ejemplo MySQL editable.

2

Escribir pregunta

Lenguaje natural en español.

3

Generar

El servicio asigna GPU y valida la salida.

4

Revisar SQL

La respuesta muestra latencia y request ID.

```
SELECT c.nombre, SUM(p.total) AS total_completado
FROM clientes AS c
JOIN pedidos AS p ON p.cliente_id = c.id
WHERE p.estado = 'completado'
GROUP BY c.id, c.nombre;
```

> La demostración usará tres preguntas: una fácil, una media y una difícil.

CONTROLES Y MONITOREO

La evidencia operativa protege privacidad y seguridad

RIESGO	CONTROL	EVIDENCIA
SQL destructivo	sqlglot rechaza DDL, DML y sentencias múltiples	Pruebas automatizadas
Entrada fuera de contrato	Longitud máxima y presencia de CREATE TABLE	Error visible y categorizado
Fuga en logs	No se guarda esquema ni pregunta	Prueba de privacidad
Saturación de GPU	Una generación simultánea	Cola y estado del runtime

> Cada evento registra fecha UTC, request ID, estado, latencia, tamaños de entrada y categoría de error.

EVIDENCIA DEL PASE A PRODUCCIÓN

El comité podrá rastrear cada afirmación

Evidencia ya verificada

- 2,592 pares y 40 preguntas con hashes congelados.
- 39/40 respuestas correctas en esquemas inéditos.
- Prueba limpia en Tesla T4.
- Suite local de 43 pruebas.

Evidencia del servicio

- HTTP 200 mediante Cloudflare.
- 3/3 consultas sintéticas correctas.
- DELETE y sentencia múltiple rechazados.
- Commit 0e304a20 y capturas registradas.

> La prueba pública operó de 16:13 a 16:17 del 5 de noviembre y el túnel se cerró después de capturar la evidencia.

SUPUESTOS Y LÍMITES

El uso responsable requiere revisión humana

SUPUESTO O LÍMITE	IMPACTO	MITIGACIÓN
DDL completo y pregunta sobre ese esquema	Entidades ausentes producen errores semánticos	Validación y mensaje claro
Datos sintéticos y dos esquemas de validación	Generalización limitada	Monitorear fallos por dominio
GPU bajo demanda	Cola o arranque en frío	Calentar servicio y tener plan local
SQL seguro puede ser incorrecto	Riesgo de una respuesta equivocada	Revisión antes de ejecutar

RECOMENDACIÓN AL COMITÉ

Mantener el modelo para consultas supervisadas

97.4%

EX ponderada frente a 3.8% del baseline

Condiciones de operación

1. Conservar la restricción de solo lectura.
2. Exigir revisión antes de ejecutar.
3. Monitorear latencia, errores y dominios nuevos.
4. No registrar contenido del usuario.